

Classification d'images télévisées

FARHAD - HEYBATI
YUCEF - KACER
MARTIN - PROVOST

9 May 2016

Table des matières

Introduction	i
1 Images exploitées	1
1.1 Corpus et labélisation	1
1.2 Classification binaire	3
2 Extraction d'information	7
2.1 Extraction de contours	7
2.2 Extraction de teinte	7
2.3 Histogramme orienté du gradient	7
2.4 Réseaux de neurones à convolution pré-entraîné	7
3 Résultats	11
3.1 Extraction de contours	11
3.2 Extraction de teinte	11
3.3 Histogramme orienté du gradient	11
3.4 Réseaux de neurones à convolution pré-entraîné	11

Introduction

Ce document présente plusieurs méthodes d'extraction d'informations à partir d'images issues d'un débat télévisé. Cela afin d'en effectuer une classification binaire en « gros plan » ou « large plan ». Nous proposons dans un premier chapitre de présenter les images exploitées, et les deux classes qui nous intéressent. Dans une seconde partie, nous présentons les méthodes d'extraction d'informations utilisées. Puis dans une troisième partie, les résultats obtenus.

Chapitre 1

Images exploitées

1.1 Corpus et labélisation

Nous allons exploiter un total de 2351 images prises à partir de la vidéo d'un débat télévisé [Ess16]. Nous avons exploité le fichier de transcription au format .trs [Ess16] associé à cette vidéo, cela afin d'extraire les différentes classes, et attribuer à chaque image sa classe. En effet, le fichier de transcription fournit un total de 9 classes :

M : La présentatrice est seule à l'écran

A : La première intervenante est seule à l'écran

B : La seconde intervenante est seule à l'écran

C : Le premier intervenant est seul à l'écran

D : Le second intervenant est seul à l'écran

ALL : Les 5 personnes sont à l'écran

MULTI : Entre 2 et 4 personnes sont à l'écran

INTRO : Reportage d'introduction à l'écran

CREDITS : Générique d'émission à l'écran

Par ailleurs, le fichier de transcription donne à chaque intervalle de temps, ce qui est à l'écran parmi les classes citées plus-haut. Moyennant une conversion du fichier au format xml, on peut obtenir le tableau suivant :

classe	debut (s)	fin (s)
<i>CREDITS</i>	0	11.36
<i>INTRO</i>	11.36	84.64
<i>M</i>	84.64	95.12
<i>ALL</i>	95.12	103.2
<i>A</i>	103.2	112.2
<i>M</i>	112.2	115.24
⋮	⋮	⋮
<i>M</i>	2334.12	2340
<i>ALL</i>	2340	2340.76
<i>CREDITS</i>	2340.76	2349.72

TABLE 1.1 – Table de correspondance classes/intervalle de temps

Les 2351 images étant prises à une seconde d'intervalle tout le long de la vidéo, on peut automatiquement labéliser celles ci via la table de correspondance 1.1. Ci-après, nous présentons quelques images pour chacune des 9 classes (Cf. figures 1.1,1.2,1.3,1.4,1.5, 1.6,1.7,1.8,1.9).

1.2 Classification binaire

Par la suite, nous allons nous restreindre à seulement deux classes définies comme suit :

G : « Gros plan » (une seule personne est à l'écran)

L : « Large plan » (au moins deux personnes sont à l'écran)

Les classes G et L peuvent s'exprimer en fonction des 9 classes comme suit :

$G : M \mid A \mid B \mid C \mid D$

$L : ALL \mid MULTI$

Nous avons donc deux classes d'images G et L (respectivement 1491 et 761 images) (Cf. figures 1.10 et 1.11)

Par la suite, nous allons expliciter différentes manières d'extraire de l'information afin de pouvoir discriminer les images de classe G , des images de classe L .

FIGURE 1.1 – image de classe M FIGURE 1.2 – image de classe A FIGURE 1.3 – image de classe B FIGURE 1.4 – image de classe C



FIGURE 1.5 – image de classe *D*



FIGURE 1.6 – image de classe *ALL*



FIGURE 1.7 – image de classe *MULTI*



FIGURE 1.8 – image de classe *INTRO*

FIGURE 1.9 – image de classe *CREDITS*FIGURE 1.10 – image de classe *G* (gros plan)FIGURE 1.11 – image de classe *L* (large plan)

Chapitre 2

Extraction d'information

2.1 Extraction de contours

2.2 Extraction de teinte

2.3 Histogramme orienté du gradient

Cette méthode consiste à extraire l'information local de contours. Historiquement, sa première utilisation a consisté en la détection de piétons [DT05]. Pour une image donnée, le vecteur descripteur des *HOG* est la concaténation d'histogrammes de l'amplitude du gradient (en fonction de son orientation). Chaque histogramme est pris sur un carré de l'image appelé « cellule ». L'ensemble des cellules quadrille entièrement l'image avec un éventuel recouvrement.

Ces histogrammes sont ensuite normalisés en intensité par paquet de cellules adjacentes (appelés « block ») afin d'obtenir des descripteurs invariants au changement local d'illumination (Cf. figure 2.1).

On peut espérer que ces descripteurs s'adaptent bien à notre problème. En effet, les épaules des intervenants à gauche et à droite de l'image, ainsi que leur visage, sont des contours discriminants pour la classe G (gros plan) (Cf. figure 2.2). D'autre part, les gros plans ont un fond uniforme, ce qui donnera beaucoup de gradient nul, et donc un descripteur *sparse* pour la classe G (gros plan).

2.4 Réseaux de neurones à convolution pré-entraîné

Cette méthode consiste à extraire les descripteurs produits par un réseau de neurones à convolution déjà entraîné. En effet, en récupérant la sortie de l'avant-dernière couche, on obtient la transformation finale haut-niveau de l'image, avant la couche de classification. Cette technique est connue sous le nom de *Transfer Learning* [YCBL14] et a fait ses preuves dans le cas de réseaux de neurones entraînés sur la base d'images *ImageNet* [DDS⁺09]. Cette base de près de 10

millins d'images, contient une multitude de classes (animaux,ustensiles,humains,...) organisées hiérarchiquement, et on peut espérer que les gros plans (classe G) correspondent à l'une de ces classes,et de même pour les images plan large (classe L), de telle sorte qu'on puisse ensuite séparer les descripteurs via un classifieur supervisé.




FIGURE 2.1 – Construction d'un histogramme orienté du gradient [Lev13]

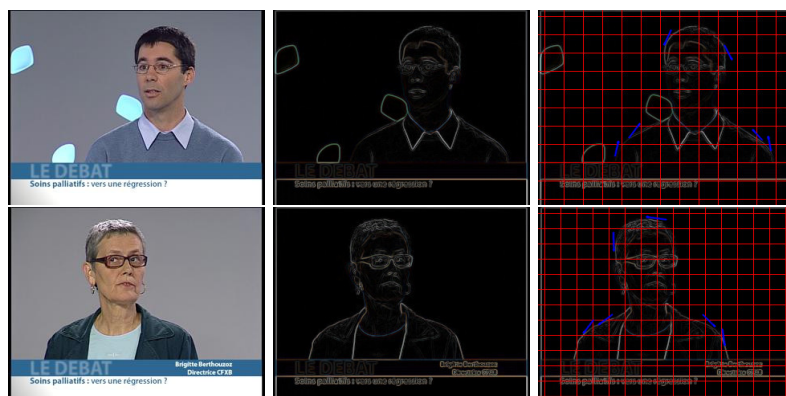


FIGURE 2.2 – Histogramme orienté du gradient pour les gros plans (classe G)

Chapitre 3

Résultats

3.1 Extraction de contours

3.2 Extraction de teinte

3.3 Histogramme orienté du gradient

Nous avons extrait les descripteurs *HOG* pour chacune des images de classe G et L , en utilisant une cellule de taille 32x32 (sans recouvrement) de sorte à récupérer les formes des épaules et du visage, et non les détails plus petits liés au port de lunettes par exemple. Pour la normalisation, nous l'avons effectué par groupe de carré à 4 cellules (avec recouvrement) afin de tenir compte du fait qu'au sein des gros plans, les intervenants peuvent être légèrement décalés. Puis, nous avons appliqué à ces descripteurs, différents classifieurs supervisés. Nous avons découpé le set de descripteurs en deux sous-ensembles représentant 70% du total pour l'entraînement, 30% pour le test. Les résultats de classification sont illustrés dans la table 3.1.

Les classifieurs utilisés sont ceux de la librairie *Scikit-Learn*, implémentés dans le script *Python* tiré de [PGBB14], que nous avons adaptés.

3.4 Réseaux de neurones à convolution pré-entraîné

Nous avons utilisé le code *Overfeat* [SEZ⁺13], récupéré par clonage du dépôt Github correspondant [SEZ⁺14], pré-entraîné sur la base *ImageNet* [DDS⁺09]. Nous avons extrait les descripteurs pour chacune des images de classe G et L pour leur appliquer différents classifieurs supervisés. Nous avons découpé le set de descripteurs en deux sous-ensembles 70% du total pour l'entraînement, 30% pour le test. Les résultats de classification sont illustrés dans la table 3.2.

classifieur	score de test	temps de training (s)	temps de test (s)
Ridge Classifier	1.0	0.130	0.027
Perceptron	1.0	0.219	0.028
Passive-Aggressive	1.0	0.352	0.024
kNN	0.998	0.221	2.875
Random forest	1.0	1.321	0.012
linear SVM - L2 penalty	1.0	0.197	0.024
SGDClassifier - L2 penalty	1.0	0.202	0.024
linear SVM - L1 penalty	1.0	0.283	0.024
SGDClassifier - L1 penalty	1.0	0.634	0.024
SGDClassifier - ElasticNet penalty	1.0	0.721	0.024
NearestCentroid	0.996	0.049	0.028
SVM	0.998	0.446	0.203
linear SVM - L1 penalty - dual=False	1.0	0.238	0.003

TABLE 3.1 – Résultats de classification supervisée sur les descripteurs *HOG*

classifieur	score de test	temps de training (s)	temps de test (s)
Ridge Classifier	1.0	0.762	0.152
Perceptron	0.998	1.515	0.155
Passive-Aggressive	1.0	1.852	0.150
kNN	0.998	1.456	16.77
Random forest	0.998	3.851	0.024
linear SVM - L2 penalty	1.0	1.105	0.149
SGDClassifier - L2 penalty	0.998	1.156	0.153
linear SVM - L1 penalty	1.0	1.220	0.149
SGDClassifier - L1 penalty	1.0	5.581	0.149
SGDClassifier - ElasticNet penalty	1.0	6.062	0.151
NearestCentroid	0.987	0.302	0.221
SVM	1.0	3.508	1.591
linear SVM - L1 penalty - dual=False	1.0	1.150	0.011

TABLE 3.2 – Résultats de classification supervisée sur les descripteurs *Overfeat*

Liste des tableaux

1.1	Table de correspondance classes/intervalle de temps	2
3.1	Résultats de classification supervisée sur les descripteurs <i>HOG</i> .	12
3.2	Résultats de classification supervisée sur les descripteurs <i>Overfeat</i>	12

Table des figures

1.1	image de classe <i>M</i>	4
1.2	image de classe <i>A</i>	4
1.3	image de classe <i>B</i>	4
1.4	image de classe <i>C</i>	4
1.5	image de classe <i>D</i>	5
1.6	image de classe <i>ALL</i>	5
1.7	image de classe <i>MULTI</i>	5
1.8	image de classe <i>INTRO</i>	5
1.9	image de classe <i>CREDITS</i>	6
1.10	image de classe <i>G</i> (gros plan)	6
1.11	image de classe <i>L</i> (large plan)	6
2.1	Construction d'un histogramme orienté du gradient [Lev13] . . .	9
2.2	Histogramme orienté du gradient pour les gros plans (classe <i>G</i>) .	9

Bibliographie

- [DDS⁺09] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. ImageNet : A Large-Scale Hierarchical Image Database. In *CVPR09*, 2009.
- [DT05] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. *cvpr*, jun 2005.
- [Ess16] Slim Essid. Resources, 2016.
- [Lev13] Gil Levi. A short introduction to descriptors, aug 2013.
- [PGBB14] Peter Prettenhofer, Olivier Grisel, Mathieu Blondel, and Lars Buitinck. Classification of text documents using sparse features, 2014.
- [SEZ⁺13] Pierre Sermanet, David Eigen, Xiang Zhang, Michaël Mathieu, Rob Fergus, and Yann LeCun. Overfeat : Integrated recognition, localization and detection using convolutional networks. *CoRR*, abs/1312.6229, 2013.
- [SEZ⁺14] Pierre Sermanet, David Eigen, Xiang Zhang, Michaël Mathieu, Rob Fergus, and Yann LeCun. Overfeat code source, 2014.
- [YCBL14] Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? *CoRR*, abs/1411.1792, 2014.